

# PIE2: ENTREGABLE 1

Eki González i Biel Peràlvarez

2024-10-23

## Exercici 1

Sigui  $X$  una variable aleatòria amb distribució Gamma de paràmetres  $\alpha = M$  (on  $M$  és el número que teniu associat al fitxer parelles.pdf) i  $\beta$  desconegut (feu servir la parametrització forma-escala que és la primera que surt al fitxer “Distribucions de probabilitat” que teniu penjat a ATENEA). Assumiu que  $\mathbf{x} = (x_1, x_2, \dots, x_n)$  és una mostra aleatòria simple de  $X$ .

## PART TEÒRICA

a. Trobeu l'estimador de  $\beta$  aplicant el mètode de moments i el de màxim versemblança. Coincideixen?

Per aquest apartat utilitzarem la funció de distribució de la gamma:

$$f(x; \alpha, \beta) = \frac{1}{\Gamma(\alpha)\beta^\alpha} \cdot x^{\alpha-1} e^{-x/\beta}, \quad x > 0, \alpha, \beta > 0$$

on  $\Gamma(z) = \int_0^\infty t^{z-1} e^{-t} dt$ ,  $z > 0$ .

També utilitzarem la següent propietat d'aquesta funció:  $\Gamma(z+1) = z\Gamma(z)$ .

**Demostració:**  $\Gamma(z+1) = \int_0^\infty t^z e^{-t} dt = t^z(-e^{-t})|_0^\infty + \int_0^\infty z t^{z-1} e^{-t} dt = 0 + z\Gamma(z)$

1. Mètode de moments:  $\mu = \mathbb{E}[X] = \bar{x}$ , recordem que  $\alpha = M$

Calculem l'esperança:

$$\begin{aligned} \mathbb{E}[X] &= \int_0^\infty x \cdot f(x; \alpha, \beta) dx = \frac{1}{\Gamma(M)\beta^M} \int_0^\infty x^M e^{-x/\beta} dx = \frac{1}{\Gamma(M)\beta^M} \int_0^\infty (\beta \cdot t)^M e^{-t} \cdot \beta dt = \\ &= \frac{\beta^{M+1}}{\Gamma(M)\beta^M} \int_0^\infty t^M e^{-t} dt = \frac{\beta}{\Gamma(M)} \Gamma(M+1) = \frac{\beta}{\Gamma(M)} \cdot M \cdot \Gamma(M) = M\beta \end{aligned}$$

on hem utilitzat el canvi de variable:  $t = \frac{x}{\beta} \rightarrow x = \beta t \rightarrow dx = \beta dt$

Per tant:  $\bar{x} = M\beta \rightarrow \beta = \frac{\bar{x}}{M} \rightarrow \hat{\beta} = \frac{\bar{x}}{M}$  és l'estimador.

## 2. Mètode de màxima versemblança:

Sigui  $\mathcal{L}$  la funció de versemblança i  $\mathbf{x}$  una mostra:

$$\mathcal{L}(\beta; \mathbf{x}) = \prod_{i=1}^n f(x_i; M, \beta)$$

$$\begin{aligned} \log(\mathcal{L}(\beta; \mathbf{x})) &= \sum_{i=1}^n \log \left( \frac{1}{\Gamma(M)\beta^M} \cdot x_i^{M-1} e^{-x_i/\beta} \right) = \sum_{i=1}^n \left[ \log(x_i^{M-1}) + \log(e^{-x_i/\beta}) \right] - \sum_{i=1}^n [\log(\Gamma(M)) + \log(\beta^M)] \\ &= \sum_{i=1}^n \left[ (M-1) \log(x_i) - \frac{x_i}{\beta} \right] - n \log(\Gamma(M)) - nM \log(\beta) = (M-1) \sum_{i=1}^n \log(x_i) - \sum_{i=1}^n \frac{x_i}{\beta} - n \log(\Gamma(M)) - nM \log(\beta). \end{aligned}$$

Igualem la derivada a zero per a trobar el màxim:

$$\frac{\partial}{\partial \beta} \log(\mathcal{L}(\beta; \mathbf{x})) = \frac{\partial}{\partial \beta} \left( - \sum_{i=1}^n \frac{x_i}{\beta} - nM \log(\beta) \right) = \sum_{i=1}^n \frac{x_i}{\beta^2} - \frac{nM}{\beta} = 0$$

Per tant:

$$\frac{1}{\beta^2} \sum_{i=1}^n x_i = \frac{nM}{\beta} \Leftrightarrow \frac{1}{n} \sum_{i=1}^n x_i = \frac{\beta^2 M}{\beta} \Leftrightarrow \bar{x} = \beta M \rightarrow \hat{\beta} = \frac{\bar{x}}{M} \text{ és l'estimador.}$$

Comprovem que certament aquest valor és un màxim amb la segona derivada.

$$\frac{\partial^2}{\partial \beta^2} \log(\mathcal{L}(\beta; \mathbf{x})) = \frac{d}{d\beta} \left( \sum_{i=1}^n \frac{x_i}{\beta^2} - \frac{nM}{\beta} \right) = - \sum_{i=1}^n \frac{2x_i}{\beta^3} + \frac{nM}{\beta^2}$$

Substituïm el valor de  $\beta$  a la segona derivada i veiem que és negativa.

$$\frac{\partial^2}{\partial \beta^2} \log(\mathcal{L}(\frac{\bar{x}}{M}; \mathbf{x})) = - \frac{2n\bar{x}M^3}{\bar{x}^3} + \frac{nM^3}{\bar{x}^2} = \frac{-2n\bar{x}M^3 + n\bar{x}M^3}{\bar{x}^3} = \frac{-n\bar{x}M^3}{\bar{x}^3} = \frac{-nM^3}{\bar{x}^2} < 0$$

Per tant, hem vist que pels dos mètodes l'estimador coincideix. Com en el nostra cas  $M = 1 \rightarrow \hat{\beta} = \bar{x}$ .

**b. Escriu de forma explícita la distribució asimptòtica de l'estimador màxim versemblant de  $\beta$  ( $\hat{\beta}$ ).**

Sabem per teoria que, si  $\hat{\beta}$  és un estimador màxim-versemblant de  $\beta$ , llavors  $\hat{\beta} \sim N(\beta, (I(\beta))^{-1})$

En aquest cas:

$$\begin{aligned} I(\beta) &= \mathbb{E} \left[ - \frac{\partial^2}{\partial \beta^2} \log(\mathcal{L}(\beta; \mathbf{x})) \right] = \mathbb{E} \left[ \frac{2}{\beta^3} \sum_{i=1}^n x_i - \frac{nM}{\beta^2} \right] = - \frac{nM}{\beta^2} + \frac{2}{\beta^3} \mathbb{E} \left[ \sum_{i=1}^n x_i \right] = - \frac{nM}{\beta^2} + \frac{2}{\beta^3} \sum_{i=1}^n \mathbb{E}[x] = \\ &= - \frac{nM}{\beta^2} + \frac{2nM\beta}{\beta^3} = \frac{(2-1)nM}{\beta^2} = \frac{nM}{\beta^2} \end{aligned}$$

Per tant,  $\hat{\beta} \sim N(\beta, \frac{\beta^2}{nM})$

c. Estimeu la variància de  $\hat{\beta}$  substituint  $\beta$  per la seva estimació, i a partir de la distribució asimptòtica de l'estimador màxim versemblant, trobeu explícitament (igual com s'ha fet a classe) un Interval de Confiança pel paràmetre  $\beta$  al 90.

Sabem que  $Var(\hat{\beta}) = \frac{\beta^2}{nM}$  per tant al substituir:  $\hat{\beta} \sim N(\beta, \frac{\hat{\beta}^2}{nM}) \rightarrow \frac{\hat{\beta} - \beta}{\sqrt{\frac{\hat{\beta}^2}{nM}}} \sim N(0, 1)$

Per tant:

$$\mathbb{P}(-Z_{\frac{\alpha}{2}} \leq \frac{\hat{\beta} - \beta}{\frac{\hat{\beta}}{\sqrt{nM}}} \leq Z_{\frac{\alpha}{2}}) = 1 - \alpha$$

$$\mathbb{P}(-Z_{\frac{\alpha}{2}} \frac{\hat{\beta}}{\sqrt{nM}} \leq \hat{\beta} - \beta \leq Z_{\frac{\alpha}{2}} \frac{\hat{\beta}}{\sqrt{nM}}) = 1 - \alpha$$

$$\mathbb{P}(-\hat{\beta} - Z_{\frac{\alpha}{2}} \frac{\hat{\beta}}{\sqrt{nM}} \leq -\beta \leq -\hat{\beta} + Z_{\frac{\alpha}{2}} \frac{\hat{\beta}}{\sqrt{nM}}) = 1 - \alpha$$

$$\mathbb{P}(\hat{\beta} + Z_{\frac{\alpha}{2}} \frac{\hat{\beta}}{\sqrt{nM}} \geq \beta \geq \hat{\beta} - Z_{\frac{\alpha}{2}} \frac{\hat{\beta}}{\sqrt{nM}}) = 1 - \alpha$$

$$IC_{1-\alpha}[\beta] = \hat{\beta} \pm Z_{\frac{\alpha}{2}} \frac{\hat{\beta}}{\sqrt{nM}}$$

En el nostra cas ( $M = 1$ ), si  $1 - \alpha$  és el 90,  $\alpha$  és 10 i  $Z_{0.05} = 1.64 \rightarrow IC_{1-\alpha}[\beta] = \hat{\beta} \pm Z_{0.05} \frac{\hat{\beta}}{\sqrt{n}}$

## PART PRÀCTICA


a. Genereu aleatòriament 150 dades d'una Gamma ( $M, 7.8$ ) i il·lustreu-les. Compareu el vostre plot amb el de la funció de densitat de la Gamma pertinent. Què deduiu?

```
# Tenim assignat el numero 1
M = 1

# Generem les 150 dades fixant una "seed" per poder comparar els resultats
set.seed(123)
dades = rgamma(150, shape = M, scale = 7.8)

# Histograma superposat amb la funció de densitat
hist(dades, probability = TRUE, main = "Histograma de dades Gamma", xlab = "Valor", ylab = "Densitat")
curve(dgamma(x, shape = M, scale = 7.8), col = "red", lwd = 2, lty = 5, add = TRUE)
legend("topright", legend = c("Dades generades", "Densitat teòrica"), col = c("black", "red"), lwd = 2)
```

## Histograma de dades Gamma




```
# Distribució empírica
```

```
plot(ecdf(dades), main = "Distribució de dades Gamma")
```

```
curve(pgamma(x, shape = M, scale = 7.8), col = "red", lwd = 2, lty = 5, add = TRUE)
```

```
legend("bottomright", legend = c("Distribució empírica", "Distribució teòrica"), col = c("black", "red"))
```

## Distribució de dades Gamma



Veient la comparació dels gràfics de la nostra Gamma amb la funció de densitat pertinent, podem observar que bàsicament és manté la relació de les dades i l'histograma decreix tan ràpidament com la funció de densitat.

Tot i això, hi ha alguns intervals que sobrepassen o no arriben a la funció de densitat, per poder comparar millor el plot amb la funció corresponent, hem visualitzat la distribució de probabilitat acumulada i hem deduït que amb 150 dades ja és suficient per assimilar-se a una distribució gamma.

**b1. L'esperança i la variància mostrals s'assemblen a les teòriques? Calculeu-ne el valor absolut de la diferència.**

```
M = 1

# Generem les 150 dades fixant una "seed" per poder comparar els resultats
set.seed(123)
dades = rgamma(150, shape = M, scale = 7.8)

dades_avg = mean(dades)
dades_var = var(dades)

dades_avg

## [1] 7.262698

dades_var

## [1] 54.14813
```

```
error_avg = abs(dades_avg - M*7.8)
error_var = abs(dades_var - M*7.8*7.8)

error_avg
```

```
## [1] 0.5373018
```

```
error_var
```

```
## [1] 6.691874
```

Podem observar que els valors de l'esperança i variància s'assemblen considerablement als valors teòrics. Tot i això, els errors s'han de tenir en compte, sobretot el de la variància, ja que representa un 0.11% del valor teòric. En canvi, l'esperança un 0.06.

**b2. Trobeu l'e.m.v. de  $\beta$  a partir de les dades i compareu-lo amb el teòric.**

```
beta_est = dades_avg/M
beta_est
```

```
## [1] 7.262698
```

**c. Trobeu a partir de les vostres dades l'Interval de Confiança per  $\beta$  al 90.**

Hem vist a la part teòrica que, en el nostra cas:  $IC_{1-\alpha}[\beta] = \hat{\beta} \pm Z_{0.05} \frac{\hat{\beta}}{\sqrt{n}}$  Per tant:

```
z = qnorm(0.05, lower.tail = FALSE)
IC_left = beta_est - z*beta_est/sqrt(150)
IC_right = beta_est + z*beta_est/sqrt(150)
IC_left
```

```
## [1] 6.287305
```

```
IC_right
```

```
## [1] 8.238091
```

En conclusió:  $IC_{90}[\beta] = [6.287, 8.238]$

## Exercici 2

S'ha mesurat el contingut en sodi i les calories de dos tipus de salsitxes: de gall d'indi i de vedella. Les salsitxes son de forma mitjana, i tenen un pes d'aproximadament 60 gr. Les dades les trobareu en el fitxer dadesM.csv (on la M és el número que teniu associat al fitxer parelles.pdf).

**a. Compareu mitjançant gràfics els continguts de sodi dels dos tipus de salsitxes. Què deduïu?.**

```
library(ggplot2)


## Warning: package 'ggplot2' was built under R version 4.3.3

dades = read.csv("dades1.csv")

# Canviem les "," per "." dels decimals
dades$Sodi = as.numeric(gsub(",", ".", dades$Sodi))
dades$Calories = as.numeric(gsub(",", ".", dades$Calories))

# Calculem les mitjanes de sodi per cada tipus
mitjana_vedella = mean(dades$Sodi[dades$Tipus == "Vedella"])
mitjana_gall_dindi = mean(dades$Sodi[dades$Tipus == "Gall d'indi"])

# Diagrama de caixes
ggplot(dades, aes(x = Tipus, y = Sodi, fill = Tipus)) +
  geom_boxplot() +
  labs(title = "Comparació del contingut de sodi entre Vedella i Gall d'indi",
       y = "Sodi (mg)", x = "Tipus") +
  scale_fill_manual(values = c("Vedella" = "lightblue", "Gall d'indi" = "lightgreen")) +
  geom_hline(yintercept = mitjana_vedella, color = "blue", linetype = "dashed") +
  geom_hline(yintercept = mitjana_gall_dindi, color = "green", linetype = "dashed") +
  theme_minimal()
```



Podem veure com el contingut de sodi de les salsitxes vedella és superior al de les de gall d'indi. Excepte el punt atípic, que representa un valor de sodi molt elevat i allunyat de la resta de valors, tots els altres

valors de sodi de salistxes de gall d'indi són més baixos que els de la vedella, per tant les mitjanes i medianes també.

A més, es veu clarament per les “cues” que surten de les caixes, que els valors de sodi de la salsitxa de vedella són molt més variats que els de l'altra. Exactament van des de 520 a 610, mentre que els valors de la salsitxa de gall d'indi van de 490 a 510, si obviem el valor atípic de 550.

**b. Podem suposar que la variància de la variable sodi en les salsitxes de vedella és semblant a la de les salsitxes de gall d'indi?.**

Per a saber si podem suposar que és semblant, fem el test de comparació de variàncies. Com que les variàncies son desconegudes, les estimem:

$$S_v^2 : \text{Estimador de la variancia de les salsitxes de vedella} \quad S_v^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

On  $x_i$  són els diferents valors de sodi de la salsitxa de vedella

$$S_g^2 : \text{Estimador de la variancia de les salsitxes de Gall d'indi} \quad S_g^2 = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2$$

On  $y_i$  són els diferents valors de sodi de la salsitxa de gall d'indi

```
# Calcular els estimadors de les variancies de sodi per cada tipus
## RECORDEM: S^2 ja és est_variancia, no cal elevar al quadrat.
est_variancia_vedella = var(dades$Sodi[dades$Tipus == "Vedella"])
est_variancia_gall_dindi = var(dades$Sodi[dades$Tipus == "Gall d'indi"])
```

Per tant:  $S_v^2 = 931.08$  i  $S_g^2 = 193.24$

Segui  $H_0 : \frac{\sigma_v^2}{\sigma_g^2} = 1$  i  $H_1 : \frac{\sigma_v^2}{\sigma_g^2} \neq 1$ , considerem  $F_0 = \frac{S_v^2/\sigma_v^2}{S_g^2/\sigma_g^2} \sim F_{n_v-1, n_g-1} \rightarrow$  Si  $H_0$  és certa:  
 $F_0 = \frac{S_v^2}{S_g^2} \sim F_{n_v-1, n_g-1}$

```
n_v = (length(dades$Sodi[dades$Tipus == "Vedella"]))
n_g = (length(dades$Sodi[dades$Tipus == "Gall d'indi"]))
alpha = 0.05

F_0 = est_variancia_vedella / est_variancia_gall_dindi
F_0
```

```
## [1] 4.818216
```

```
qf(1-alpha/2, n_v - 1, n_g - 1)
```

```
## [1] 2.978588
```

```
qf(alpha/2, n_v - 1, n_g - 1)
```

```
## [1] 0.3357296
```

Com que  $F_0$  és més gran que  $F_{1-\alpha/2, n_v-1, n_g-1}$ , rebutgem  $H_0$ . Per tant, les variàncies són diferents. Comprovem per p\_valors:

```
p_valor = 2*(1 - pf(F_0, n_v - 1, n_g - 1))
p_valor
```

```
## [1] 0.005763722
```

Tal com esperàvem,  $p\_valor = 0.006 < 0.05 = \alpha$ , per tant la decisió de rebutjar  $H_0$  és la correcta.

**c. Podem concloure que no hi ha diferències estadísticament significatives entre les salsitxes de vedella i les de gall d'indi en quant a contingut de sodi? ( $\alpha = 0.05$ ). Contesteu aquesta pregunta mitjançant: i) punts crítics, ii) p-valors, iii) Intervals de confiança.**

Dels resultats obtinguts a l'apartat anterior, sabem que ambdues poblacions tenen variàncies desconegudes i estadísticament diferents. Per aquest motiu, compararem les mitjanes de les dues poblacions assumint normalitat en aquesta situació. Recordem la derivació:

$$\bar{X} \sim N\left(\mu_v, \frac{\sigma_v^2}{n_v}\right) \quad \bar{Y} \sim N\left(\mu_g, \frac{\sigma_g^2}{n_g}\right) \quad \Rightarrow \quad \frac{(\bar{x} - \bar{y}) - (\mu_v - \mu_g)}{\sqrt{\frac{\sigma_v^2}{n_v} + \frac{\sigma_g^2}{n_g}}} \sim N(0, 1)$$

Siguin  $H_0 : \mu_v = \mu_g$   $H_1 : \mu_v \neq \mu_g$ . Llavors assumint  $H_0$  com certa i estimant les variàncies, obtenim:

$$\frac{\bar{x} - \bar{y}}{\sqrt{\frac{s_v^2}{n_v} + \frac{s_g^2}{n_g}}} \sim t_\nu \quad \nu = \frac{\left(\frac{s_v^2}{n_v} + \frac{s_g^2}{n_g}\right)^2}{\frac{1}{n_v-1} \left(\frac{s_v^2}{n_v}\right)^2 + \frac{1}{n_g-1} \left(\frac{s_g^2}{n_g}\right)^2}$$

A continuació, calcularem el nombre de graus de llibertat  $\nu$  (arrodonim si no és enter) i respondrem a la pregunta sobre la diferència estadística utilitzant els diferents mètodes sol·licitats.

```
nu = (est_variancia_vedella/n_v + est_variancia_gall_dindi/n_g)^2 / ((est_variancia_vedella/(n_v))^2/(n_v-1) + (est_variancia_gall_dindi/(n_g))^2/(n_g-1))
nu
```

```
## [1] 19.57129
```

```
nu_rounded = 20
```

```
estadistic_prova = (mitjana_vedella - mitjana_gall_dindi) / sqrt(est_variancia_vedella/n_v + est_variancia_gall_dindi/n_g)
# Per punts crítics:
estadistic_prova
```

```
## [1] 8.792985
```

```
qt(alpha/2, nu_rounded, lower.tail = FALSE)
```

```
## [1] 2.085963
```

Rebutgem  $H_0$ , ja que  $8.79 > 2.08 = t_{\alpha/2}$

```
# Per p-valors.
p_valor = 2*(1 - pt(estadistic_prova, nu_rounded))
p_valor
```

```
## [1] 2.626695e-08
```

Podem veure que també coincideix en que s'ha de rebutjar, perquè  $2.6 \times 10^{-8} < 0.05$ .

```
# Per intervals de confiança (Fòrmula demostrada a classe [procediment anàleg al de l'exercici 1])
IC_95_left = (mitjana_vedella - mitjana_gall_dindi) - qt(alpha/2, nu_rounded, lower.tail = FALSE) * sqrt(est_variancia_gall_dindi)
IC_95_right = (mitjana_vedella - mitjana_gall_dindi) + qt(alpha/2, nu_rounded, lower.tail = FALSE) * sqrt(est_variancia_gall_dindi)
IC_95_left
```

```
## [1] 58.06711
```

```
IC_95_right
```

```
## [1] 94.18623
```

Per tant, l'interval és [58.07, 94.19]. Com que aquest interval no inclou el zero, la diferència entre les mitjanes és significativament diferent de zero, per tant rebutgem  $H_0$ .

#### d. Podem suposar que les salsitxes de gall d'indi tenen un contingut de sodi superior a 500 mgr per salsitxa?

Volem fer un test d'hipòtesi, amb variància desconeguda, considerant el valor mitjà de les salsitxes de gall d'indi i  $\alpha = 0.05$ . Serà el següent:

$H_0 : \mu = 500$  i  $H_1 : \mu > 500$ , considerem  $\frac{\bar{y} - \mu}{S_g / \sqrt{n_g}} \sim t_{n_g - 1} \rightarrow$  Si  $H_0$  és certa:  $t_0 = \frac{\bar{y} - 500}{S_g / \sqrt{n_g}} \sim t_{n_g - 1}$

```
desviacio_estandard = sqrt(est_variancia_gall_dindi)
t_0 = (mitjana_gall_dindi - 500) / (desviacio_estandard / sqrt(n_g))
t_0
```

```
## [1] 1.578782
```

```
qt(alpha, n_g - 1, lower.tail = FALSE)
```

```
## [1] 1.76131
```

Com que  $t_0$  és més petit que  $t_{\alpha/2, n_g - 1}$ , no rebutgem  $H_0$ . Per tant, podem suposar que les salsitxes de gall d'indi no tenen un conjunt de sodi superior a 500 mgr per salsitxa.

Per assegurar-nos, comprovem per p\_valors:

```
p_valor = 1 - pt(t_0, n_g - 1)

# Comprovem amb t.test implementat a R
resultado <- t.test(dades$Sodi[dades$Tipus == "Gall d'indi"], mu = 500, alternative = "greater")
print(resultado)
```

```
##
## One Sample t-test
##
## data:  dades$Sodi[dades$Tipus == "Gall d'indi"]
## t = 1.5788, df = 14, p-value = 0.06835
## alternative hypothesis: true mean is greater than 500
## 95 percent confidence interval:
##  499.3449      Inf
## sample estimates:
## mean of x
##  505.6667
```

```
# Els nostres resultats:
paste("Mean:", mitjana_gall_dindi)
```

```
## [1] "Mean: 505.666666666667"
```

```
paste("t:", t_0)
```

```
## [1] "t: 1.57878178188662"
```

```
paste("Degrees of freedom (df):", n_g - 1)
```

```
## [1] "Degrees of freedom (df): 14"
```

```
paste("p-value:", p_valor)
```

```
## [1] "p-value: 0.0683542090359125"
```

Tal com esperàvem,  $p\_valor = 0.068 > 0.05 = \alpha$ , per tant la decisió de no rebutjar  $H_0$  és la correcta.

**e. Calculeu un interval de confiança al 95% per la diferència de sodi entre una salsitxa de vedella i una de gall d'indi. Què es podria fer per tal de reduir l'amplitud d'aquest interval?.**

Utilitzant un desenvolupament similar al de l'apartat c, l'interval de confiança serà el següent:

$$\frac{(\bar{x} - \bar{y}) - (\mu_v - \mu_g)}{\sqrt{\frac{s_v^2}{n_v} + \frac{s_g^2}{n_g}}} \sim t_\nu \quad \Rightarrow \quad IC_{1-\alpha}(\mu_v - \mu_g) = (\bar{x} - \bar{y}) \pm t_{\nu; \alpha/2} \sqrt{\frac{s_v^2}{n_v} + \frac{s_g^2}{n_g}}$$

```
alpha = 0.05
IC_95_left = (mitjana_vedella - mitjana_gall_dindi) - qt(alpha/2, nu_rounded, lower.tail = FALSE) * sqrt(...)
IC_95_right = (mitjana_vedella - mitjana_gall_dindi) + qt(alpha/2, nu_rounded, lower.tail = FALSE) * sqrt(...)
IC_95_left
```

```
## [1] 58.06711
```

```
IC_95_right
```

```
## [1] 94.18623
```

```
IC_95_right-IC_95_left
```

```
## [1] 36.11912
```

Per tant l'interval és  $[58.07, 94.19]$  i l'amplitud de 36.12.

Per disminuir l'amplitud d'aquest interval, podríem, en primer lloc, augmentar  $\alpha$ , ja que això implicaria una menor probabilitat de trobar el valor dins l'interval i això reduiria la seva longitud. Tot i això no és una manera gaire interessant.

D'altra banda, es podrien recopilar més dades, i amb una millor desviació estàndard de l'estadístic, aquest disminuirà. Per tant també disminuirà la longitud de l'interval. Dit amb altres paraules, si aconseguim que el valor de l'arrel quadrada sigui més petit, aconseguirem reduir l'error que sumem i restem a la diferència de mitjanes.

### Exercici 3

En un estudi ecològic sobre el comportament alimentari dels ocells, es va comptar el nombre de salts ( $n$ ) entre vols per a uns quants ocells. Les dades les teniu al fitxer `ocellsM.csv` (on  $M$  és el nombre que teniu associat al fitxer `parelles.pdf`). Es suposa que la variable “Nombre de salts entre vols” segueix una distribució geomètrica amb suport  $\{1, 2, 3, \dots\}$ . Es vol saber si es pot assumir que  $p = 0.3$ . Apliqueu el test de la raó de versemblança per respondre aquesta pregunta. i) Quin és l'estadístic de prova?. ii) Quin és el p-valor? iii) Què concloeu? .

Considerem el test següent:  $H_0 : p = 0.3$  i  $H_1 : p \neq 0.3$ . Per tant:  $\theta_0 = 0.3$  i  $\theta_1 = [0, 1] - 0.3$ . A més,  $\Theta$  i  $S = \mathbb{Z}^+$  i  $\dim \Theta - \dim \theta_0 = 1 - 0 = 1$

Per a trobar l'estadístic de prova  $\mathcal{X}_0^2$  realitzarem el desenvolupament següent:

$$X \sim \text{Geom}(p) \quad \therefore \mathbb{P}(X = x) = p(1-p)^{x-1} \quad \implies \mathcal{L}(p, \mathbf{x}) = \prod_{i=1}^n \mathbb{P}(X = x_i) \mathcal{L}(p, \mathbf{x}) = \prod_{i=1}^n p(1-p)^{x_i-1} = p^n (1-p)^{-n} (1-p)^{\sum_{i=1}^n x_i}$$

Comprovem que el punt que hem trobat és un màxim amb la segona derivada.

$$\frac{\partial l}{\partial p} = \frac{n}{p} + \frac{n}{1-p} + n\bar{x} \frac{-1}{1-p} \frac{\partial^2 l}{\partial p^2} = -\frac{n}{p^2} + \frac{n}{(1-p)^2} - n\bar{x} \frac{1}{(1-p)^2} < 0 \frac{n}{(1-p)^2} < \frac{n}{p^2} + n\bar{x} \frac{1}{(1-p)^2}$$

Aquesta desigualtat és certa, ja que  $n > 0$ ,  $\bar{x} > 1$  i els quadrats també:

$$\frac{n}{p^2} + n\bar{x} \frac{1}{(1-p)^2} > n\bar{x} \frac{1}{(1-p)^2} > \frac{n}{(1-p)^2}$$

A més, sabem que es pot demostrar que:

$$\mathcal{X}_0^2 = -2 \log \lambda(x) = -2[l(0.3; \mathbf{x}) - l(\hat{p}; \mathbf{x})] \sim \chi^2$$

Després de trobar l'estadístic de prova, calculem el seu valor:

```
logL <- function(p, x, n){
  n*log(p) - n*log(1-p) + n* x*log(1-p)
}

dades_ocells = read.csv("ocells1.csv")
valor_ocells = dades_ocells$Valor[]
freq_ocells = dades_ocells$Frecuencia[]

n = sum(freq_ocells)
mean_valor = sum(valor_ocells*freq_ocells)/n

p_esti = 1/mean_valor
sqXi_0 = -2*( logL(0.3, mean_valor, n) - logL(p_esti, mean_valor, n))
sqXi_0
```

```
## [1] 5.649872
```

```
# Comprovem per punts crítics
qchisq(0.05, 1, lower.tail = FALSE)
```

```
## [1] 3.841459
```

ii. Calculem el p\_valor associat:

```
pchisq( sqXi_0, 1, lower.tail = FALSE )
```

```
## [1] 0.01745665
```

iii. En conclusió, podem veure que no és correcta assumir  $p = 0.3$ , ja que el p\_valor és menor a  $\alpha$  i rebutgem la  $H_0$ . A més,  $\chi_0^2$  és 5.65, que és major a 3.84, que és  $\chi_{0.05}^2$