

PiE2 Entregable 1

Ferran Alia, Haokang Chen

2024-10-11

Exercici 1

La funció de distribució d'una distribució Gamma és

$$f(X = x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-\frac{x}{\beta}}$$

on se'ns imposa que $\alpha = M = 2$.

M=2
al=2

Es suposa una mostra $x = (x_1, \dots, x_n)$.

Part teòrica

Apartat a

L'estimador de β s'anomenarà $\hat{\beta}$, que es pot trobar de dos maneres:

Moments Sabent que $E(X) = \alpha * \beta$ i que $m_1 = E(X)$:

$$m_1 = \frac{1}{n} \sum_{i=1}^n x_i = \alpha\beta \implies \beta = \frac{1}{n\alpha} \sum_{i=1}^n x_i \implies \hat{\beta} = \frac{\bar{x}}{\alpha}$$

per tant l'estimador per moments de β és $\hat{\beta} = \frac{\bar{x}}{\alpha}$

Màxima versemblança La funció de verosimilitud és

$$L(x) = \mathbb{P}(X_1 = x_1, \dots, X_n = x_n)$$

Sabent que les mostres són independents:

$$L(X) = \prod_{i=1}^n \mathbb{P}(X_i = x_i)$$

Per facilitar les operacions, s'aplica el logaritme a la funció, ja que aquesta funció no mou la coordenada x del màxim:

$$l(X) = \sum_{i=1}^n \log \left(\frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-\frac{x}{\beta}} \right) = n \log \left(\frac{1}{\Gamma(\alpha)} \right) - \alpha n \log \beta + (\alpha - 1) \sum_{i=1}^n \log(x_i) - \frac{1}{\beta} \sum_{i=1}^n x_i$$

Derivant i igualant a 0, es té que

$$l'(X) = -\frac{\alpha n}{\beta} + \frac{1}{\beta^2} \sum_{i=1}^n x_i = 0 \implies \beta = \frac{1}{\alpha n} \sum_{i=1}^n x_i$$

per lo que el estimador de β és

$$\hat{\beta} = \frac{\bar{x}}{\alpha}$$

que coincideix amb l'estimador per moments.

Apartat b

La distribució de l'estimador màxim versemblant de qualsevol paràmetre és

$$\hat{\theta} \sim N(\theta, I(\theta)^{-1})$$

Pel cas de la β , això és

$$\hat{\beta} \sim N(\beta, I(\beta)^{-1})$$

Per la β ja s'ha trobat un estimador, ara toca a calcular la informació de Fischer sabent que

$$I(\theta) = \mathbb{E} \left(-\frac{\partial^2 l}{\partial \beta^2} \right)$$

i que

$$I_n(\theta) = n * I(\theta)$$

Recuperant la primera derivada de la funció de màxima verosimilitud, si es calcula la informació d'una mostra

$$\frac{\partial l}{\partial \beta} = -\frac{\alpha}{\beta} + \frac{x}{\beta^2}$$

y s'aplica la segona derivada

$$\frac{\partial^2 l}{\partial \beta^2} = -\frac{\alpha}{\beta^2} + \frac{2x}{\beta^3} \implies I(\beta) = \frac{\alpha}{\beta^2} \implies I_n(\beta) = \frac{\alpha}{\beta^2} n$$

per la qual cosa la distribució de l'estimador és

$$\hat{\beta} \sim N \left(\beta, \frac{\beta^2}{\alpha n} \right)$$

Apartat c

En una distribució normal $N \sim (\mu, \sigma^2)$, la variancia és $Var(X) = \sigma^2$, que pel cas de la β passa a ser

$$Var(\beta) = \frac{\beta^2}{\alpha n} \implies S^2 = \frac{\hat{\beta}^2}{\alpha n} \implies S^2 = \frac{\bar{x}^2}{\alpha^3 n}$$

on S^2 és l'estimador de la variancia i on s'ha fet servir l'estimador $\hat{\beta}$.

Per tant

$$\hat{\beta} \sim N \left(\frac{\bar{x}}{\alpha}, \frac{\bar{x}^2}{\alpha^3 n} \right)$$

Per trobar un interval de confiança del 90% ($\gamma = 0.1$) s'ha de trobar la quantitat pivotal: una distribució que no depengui del paràmetre que estme estudiant. En aquest cas es pot trobar normalitzant la distribució normal:

$$\frac{\hat{\beta} - \frac{\bar{x}}{\alpha}}{\frac{\bar{x}^2}{\alpha^3 n}} \sim N(0, 1)$$

Per l'interval de confiança s'han de considerar els quantil $z_{\gamma/2}$ de la distribució normal que deixa una probabilitat de $\gamma/2$ per dalt, ja que volem un interval de probabilitat $1 - \gamma$:

$$\mathbb{P}\left(-z_{\gamma/2} < \frac{\hat{\beta} - \frac{\bar{x}}{\alpha}}{\frac{\bar{x}^2}{\alpha^3 n}} < z_{\gamma/2}\right) = 1 - \gamma$$

Operant per aïllar $\hat{\beta}$ queda que

$$\mathbb{P}\left(\frac{\bar{x}}{\alpha} - z_{\gamma/2} * \frac{\bar{x}^2}{\alpha^3 n} < \hat{\beta} < \frac{\bar{x}}{\alpha} + z_{\gamma/2} * \frac{\bar{x}^2}{\alpha^3 n}\right) = 1 - \gamma$$

Per tant, un interval de confiança del 90% per la $\hat{\beta}$ és

$$\hat{\beta} \in \left[\frac{\bar{x}}{\alpha} - z_{\gamma/2} * \frac{\bar{x}^2}{\alpha^3 n}, \frac{\bar{x}}{\alpha} + z_{\gamma/2} * \frac{\bar{x}^2}{\alpha^3 n}\right]$$

Part pràctica

Apartat a

```
set.seed(7636)


M <- 2
al <- M
be <- 7.8
n <- 150
data <- rgamma(n, shape=al, scale=be) #Mostra aleatòria de 150 valors seguint una distribució gamma

# Plot dels valors (histograma) junt amb la funció de distribució de la Gamma
hist(data, freq = FALSE, breaks = 20, main = "Histograma de Gamma",
      xlab = "x", ylab = "Frequencia", col = "lightgray", border = "black")

x <- seq(0, 50, by = 0.1)
y <- dgamma(x, shape=al, scale=be)
lines(x, y, col = "blue", lwd = 2)

legend("topright", legend = "Gamma Distribution", col = "blue", lwd = 2)
```

Histograma de Gamma



A l'histograma de la Gamma es pot veure que, tot i que hi ha petites diferències, les mostres segueixen la funció de distribució de la Gamma.

Apartat b

```
dif_mean_exp_teo = abs(al*be-mean(data))  
dif_mean_exp_teo #Diferència entre la mitjana experimental i la teòrica
```

```
## [1] 0.5579315
```

```
dif_var_exp_teo = abs(al*be*be-var(data))  
dif_var_exp_teo #Diferència entre la varianza experimental i la teòrica
```

```
## [1] 27.81795
```

Es pot veure que, en tots dos casos, la diferència entre els valors experimentals i els teòrics són molt petits, es poden considerar negligibles.

En el cas de la varianza, la diferència és de més de 20, però la varianza és de l'ordre de 120, per tant la aleatorietat fa que aquesta variï.

Apartat c

```
emv_be=mean(data)/a1 #Càlcul de la beta experimental  
emv_be # beta estimada
```

```
## [1] 8.078966
```

```
be # beta teòrica
```

```
## [1] 7.8
```

```
emv_be-be #Diferència entre beta estimada i teòrica
```

```
## [1] 0.2789657
```

La β experimental és molt similar a la β teòrica, diferint només en 0.002 unitats.

Apartat d

Com s'ha trobat a apartats anteriors, l'interval de confiança de la beta és

$$\hat{\beta} \in \left[\frac{\bar{x}}{\alpha} - z_{\gamma/2} * \frac{\bar{x}^2}{\alpha^3 n}, \frac{\bar{x}}{\alpha} + z_{\gamma/2} * \frac{\bar{x}^2}{\alpha^3 n} \right]$$

Aplicant aquesta fórmula a les dades obtingudes:

```
IC_low <- mean(data)/a1 - qnorm(0.95)*(mean(data)^2/(a1^3*n))  
IC_high <- mean(data)/a1 + qnorm(0.95)*(mean(data)^2/(a1^3*n))  
IC_low
```

```
## [1] 7.721102
```

```
IC_high
```

```
## [1] 8.436829
```

L'interval de confiança del 90% per la β és

$$IC(\beta)_{0.9} = [7.730397; 8.427534]$$

Exercici 2

Primer de tot, s'importen les dades des de l'arxiu csv.

```
library(readr)
```

```
## Warning: package 'readr' was built under R version 4.3.3
```

```
dades2 <- read.csv("dades2.csv", sep = ";")
```

Apartat a

Com es vol comparar les salsitxes dels dos tipus, es dividiran les dades en dos taules diferents, i es compararan els valors de sodi de cada tipus de carn amb un histograma:

```
vedella <- dades2[dades2$Tipus == "Vedella", ] # Dades vedella  
gallDIndi <- dades2[dades2$Tipus == "Gall d'indi", ] # Dades Gall d'indi
```

```
avg_sodi_vedella = mean(vedella$Sodi)  
avg_sodi_vedella #Mitjana de sodi en vedella
```

```
## [1] 581.2944
```

```
avg_sodi_gallDindi = mean(gallDIndi$Sodi)  
avg_sodi_gallDindi # Mitjana de sodi en gall d'indi
```

```
## [1] 505.1678
```


```
# Histograma per comparar el sodi de les dues carns.  
breaks = seq(470, 630, by = 6)
```

```
hist(gallDIndi$Sodi,  
     main = "Sodi en Gall d'indi i Vedella",  
     xlab = "Valors de Sodi",  
     ylab = "Frequencia",  
     col = "blue",  
     border = "black",  
     breaks = breaks)
```

```
abline(v = avg_sodi_gallDindi, col = "blue", lwd = 2)  
abline(v = avg_sodi_vedella, col = "red", lwd = 2)
```

```
hist(vedella$Sodi,  
     col = "red",  
     border = "black",  
     breaks = breaks,  
     add = TRUE)
```

```
legend("topright",  
       legend = c("Gall d'indi", "Vedella"),  
       fill = c("blue", "red"),  
       border = "black",  
       title = "Tipus")
```



```
par(mfrow = c(1, 1))
```

Apartat b

Veient aquesta gràfica es nota una diferencia aparent en el contingut de sodi, sembla que el gall d'indi te menys quantitat de sodi, ja que els seus valors mitjans difereixen en 76.2.

Només veient els histogrames es pot notar que els valors de sodi a la vedella son força més dispersos que els del gall d'indi. Si es calculen les variancies a partir de la mostra, es troba que, efectivament, així és.

```
var_sodi_gallDindi = var(gallDindi$Sodi)
var_sodi_vedella = var(vedella$Sodi)
abs(var_sodi_gallDindi - var_sodi_vedella) # Diferència de sodi en les dues carns
```

```
## [1] 737.8411
```

A més, si es fa el test d'hipòtesis per les variançes:

$$H_o : \sigma_v^2 = \sigma_g^2 \quad H_1 : \sigma_v^2 \neq \sigma_g^2$$

Com es comparen variançes, l'estadístic de prova i la distribució de referència és

$$F_o = \frac{\max(S_x^2, S_y^2)}{\min(S_x^2, S_y^2)} \sim F_{n_x-1, n_y-1}$$

on es rebutja H_o quan

$$F_o > F_{\alpha, n_x-1, n_y-1}$$

```
F_o = var_sodi_vedella/var_sodi_gallDindi  
F_o # estadístic de prova
```

```
## [1] 4.818216
```

```
pt_crit = qf(0.05, 14, 14)  
pt_crit # Punt crític
```

```
## [1] 0.4026209
```

Com es pot veure, F_o és major que pt_{crit} , per tant es rebutja que les dues variancies siguin iguals.

Apartat c

Ara es vol comparar el gall d'indi amb la vedella:

```
t_test_result <- t.test(vedella$Sodi, gallDindi$Sodi, var.equal = FALSE)  
t_test_result # Estudi de comparació entre les dues carns
```

```
##  
## Welch Two Sample t-test  
##  
## data: vedella$Sodi and gallDindi$Sodi  
## t = 8.793, df = 19.571, p-value = 3.141e-08  
## alternative hypothesis: true difference in means is not equal to 0  
## 95 percent confidence interval:  
## 58.04171 94.21162  
## sample estimates:  
## mean of x mean of y  
## 581.2944 505.1678
```

Això es fa primer amb el mètode dels punts crítics:

```
df <- t_test_result$parameter  
alpha <- 0.05 #confiança que es dona al test  
  
t_value <- t_test_result$statistic  
t_critic <- qt(1 - alpha/2, df)  
  
t_value # estadístic de prova
```

```
## t  
## 8.792985
```

```
t_critic # Punt crític
```

```
## [1] 2.088897
```

```
#Codi per identificar si s'ha de rebutjar la hipòtesi nul·la
if(abs(t_value) > t_critic) {
  print("Rebutgem la hipòtesi nul·la: hi ha una diferència significativa.")
} else {
  print("No podem rebutjar la hipòtesi nul·la: la diferència no és significativa.")
}
```

```
## [1] "Rebutgem la hipòtesi nul·la: hi ha una diferència significativa."
```

També es veu clarament que el p-valor calculat és inferior a l'alfa que s'està fent servir.

```
#Codi per identificar si s'ha de rebutjar la hipòtesi nul·la
if(abs(t_test_result$p.value) < alpha) {
  print("Rebutgem la hipòtesi nul·la: hi ha una diferència significativa.")
} else {
  print("No podem rebutjar la hipòtesi nul·la: la diferència no és significativa.")
}
```

```
## [1] "Rebutgem la hipòtesi nul·la: hi ha una diferència significativa."
```

I el mateix passa amb els intervals de confiança:

```
t_test_result$conf.int #Interval de confiança de la resta de les dues mu
```

```
## [1] 58.04171 94.21162
## attr(,"conf.level")
## [1] 0.95
```

Es veu que aquest interval de confiança no inclou el zero, per tant amb una probabilitat del 95% els dos paràmetres són diferents.

Apartat d

```
t_test_sodi <- t.test(gallDIndi$Sodi, mu = 500, alternative = "greater")
t_test_sodi # test de si el gall d'indi té més de 500mg de Sodi
```

```
##
## One Sample t-test
##
## data: gallDIndi$Sodi
## t = 1.4398, df = 14, p-value = 0.08596
## alternative hypothesis: true mean is greater than 500
## 95 percent confidence interval:
## 498.846 Inf
## sample estimates:
## mean of x
## 505.1678
```

Com el p-valor és superior a 0.05 (la confiança que se li ha donat), no podem concloure que el gall d'indi tingui una quantitat de sodi major que 500mg.

Apartat e

Com el sodi de la vedella i del gall d'indi segueixen normals, la seva diferencia també seguirà una normal $N(\mu_v - \mu_g, \frac{\sigma_v}{\sqrt{n_v}} + \frac{\sigma_g}{\sqrt{n_g}})$, substituïnt les sigmes per les seves estimacions, trobem que

$$\frac{\bar{x}_v - \bar{x}_g - (\mu_v - \mu_g)}{\sqrt{\frac{S_v^2}{n_v} + \frac{S_g^2}{n_g}}} \sim t_\nu$$

on

$$\nu = \frac{\left(\frac{S_v^2}{n_v} + \frac{S_g^2}{n_g}\right)^2}{\frac{\frac{S_v^2}{n_v}}{\frac{n_v-1}{n_v-1}} + \frac{\frac{S_g^2}{n_g}}{\frac{n_g-1}{n_g-1}}}$$

Amb aquesta distribució arribem a que

$$\frac{\bar{x}_1 - \bar{x}_2 - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1)$$

pero com no es sap la desviació estandard, s'estima de manera que la distribució de referencia passa a ser una t d'Students:

$$\frac{\bar{x}_1 - \bar{x}_2 - (\mu_1 - \mu_2)}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}} \sim t_\nu$$

Amb aquest estadístic de prova i aquesta distribució de referència, és trivial trobar un interval de confiança del 95%.

Si aquest interval d'econfança es troba amb el t.test, el resultat és el següent:

```
t_test_result$conf.int # Mateix interval que a l'apartat c
```

```
## [1] 58.04171 94.21162
## attr(,"conf.level")
## [1] 0.95
```

Per reduir l'amplada d'aquest interval, podem fer-ho de dues maneres: augmentant el número de mostres (n) o reduint el nivell de confiança (el 95%).

Exercici 3

Importem les dades de "Ocells2.csv"

```
library(readr)
ocells <- read.csv("Ocells2.csv", sep=",")
```

Es suposa que les dades segueixen una distribució geomètrica, de fórmula

$$p(X = k) = p(1 - p)^{k-1}$$

El test de hipotesis és $H_o : p = 0.3$, $H_1 : p \neq 0.3$.

Per resoldre aquesta hipotesis s'utilitza el test de raó de versemblança, mitjançant la distribució $-2\log(\lambda(\underline{x})) \sim \chi_d^2$.

La funció de màxima verosimilitud per la distribució geomètrica és:

$$L(p; \underline{x}) = \prod_{i=1}^n (p(1-p)^{k_i-1}) = p^n \prod_{i=1}^n (1-p)^{k_i-1}$$

Si s'hi aplica un logaritme:

$$l(p; \underline{x}) = n \log(p) + \sum_{i=1}^n \log(1-p)^{k_i-1} = n \log(p) + \log(1-p) \left[\sum_{i=1}^n (k_i) - n \right]$$

Buscant el màxim d'aquesta funció es pot trobar la p de màxima verosimilitud:

$$l'(p, \underline{x}) = 0 \implies \frac{n}{p} - \frac{1}{1-p} \left[\sum_{i=1}^n (k_i) - n \right] = 0 \implies p = \frac{1}{\frac{1}{n} \sum_{i=1}^n k_i} = \frac{1}{\bar{k}}$$

Amb aquesta p es pot trobar l'estadístic de prova, ja que

$$-2\log(\lambda(\underline{x})) = -2(l(\tilde{p}; \underline{x}) - l(\hat{p}; \underline{x}))$$

on $\tilde{p}$ és l'estimador màxim versemblant en el submodel ($p = 0.3$) i $\hat{p}$ és l'estimador màxim versemblant en el model general.

Per tant, queda que l'estadístic de prova és

$$-2 \left(n(\log(0.3) - \log(\hat{p})) + \left[\sum_{i=1}^n (k_i) - n \right] (\log(0.7) - \log(1 - \hat{p})) \right) \sim \chi_d^2$$

on $d = \dim(\tilde{p}) - \dim(\hat{p}) = 1 - 0 = 1$

Al codi escrit a continuació s'elaboren tots els càlculs numèrics per resoldre el test de hipòtesis.

```
alpha <- 0.05
p <- 0.3
n <- sum(ocells$Frequencia)
sum_ki <- sum(ocells$Frequencia*ocells$Valor)
mean_k <- sum_ki/n
estad_prova <- -2*(n*(log(p)-log(1/mean_k))+(log(1-p)-log(1-1/mean_k))*(sum_ki-n))
dist_ref <- qchisq(1-alpha, 1)

estad_prova #Estadístic de prova
```

```
## [1] 1.673441
```

```
dist_ref #Punt crític de la distribució de referència
```

```
## [1] 3.841459
```

```
estad_prova >= dist_ref # Rebutjar si True
```

```
## [1] FALSE
```

```
p_value <- 1- pchisq(estad_prova, 1)
```

```
alpha # Confiança que hem assignat a la hipòtesis
```

```
## [1] 0.05
```

```
p_value # p-valor de la distribució
```

```
## [1] 0.1957982
```

```
p_value <= alpha # Rebutjar si True
```

```
## [1] FALSE
```

No rebutgem H_o , ja que l'estadístic de prova és menor al punt crític i el p-valor és superior a la confiança de la hipòtesis.

Per tant, podem concloure que $p = 0.3$.